

Coleta de dados

Especialização em Ciência de Dados

Profa. Helen de Cássia Sousa da Costa Lima



Universidade Federal
de Ouro Preto

Roteiro

1. Introdução à coleta de dados na *web*: **Panorama atual**
2. Estratégias para coleta de dados
3. Fluxo metodológico de aplicações
4. Ética e privacidade de dados
5. **Exemplo prático**: conhecendo e usando a API do Youtube

Objetivo



O objetivo é fazer com que você dê o **primeiro passo** no ecossistema de análise de dados em mídias sociais através de **demonstrações e atividades práticas** em coleta e análise de dados.

Espero que todos saiam daqui capazes de:

- **Imaginar diferentes cenários de estudo** nestas plataformas
- **Construir *datasets*** robustos
- **Elaborar metodologias** para gerar conhecimento

Quem eu sou?

Formação Acadêmica

Ciência da Computação pela **UNESP**

Pós-Graduação

Mestrado e doutorado em Ciência da Computação pela **UFOP**

Atuação na UFOP

Professora desde 2013, atuando nas áreas:


- Computação Social
- Mineração de Dados
- Segurança e Auditoria de Sistemas

Pesquisa Atual

Pós-doutoranda na **UFMG**

Inteligência Artificial Responsável aplicada à Saúde

Mídias Sociais e a Web



Mídias Sociais e a Web

Conceito Principal

Podemos pensar em redes sociais como “*minas de dados à céu aberto*”

O Valor dos Dados

Nossos dados são o recurso mais valioso do mundo atual, gerados de forma natural em larga escala

A questão é...

Está cada dia mais difícil de nós (pessoas comuns) extrairmos esse recurso, comparado ao que foi no passado.

Mídias Sociais e a Web

Facebook puts more limits on developer access to user data

These new changes are more post-Cambridge Analytica damage control.



Swapna Krishna
Contributing Writer

Updated Mon, Jul 2, 2018 · 1 min read



Research Tools

TikTok supports independent research about our platform. Through our Research Tools, qualifying researchers in the U.S. and Europe can apply to study public data about TikTok content and accounts. We're working to provide increased access to Research Tools in the future.



Meta just closed a vital online research tool. It's bad news for the fight against misinformation

Publicado: 15 agosto 2024 23:32 -03

JeffChiu/AP

Copy link

Email

Twitter

Bluesky

Facebook

LinkedIn

WhatsApp

Telegram

For more than a decade, researchers and journalists have relied on a digital tool called CrowdTangle to track and fight the spread of viral falsehoods online.

But earlier this week, the owner of CrowdTangle, Meta, [shut the tool down](#). The tech giant has replaced it with its new Content Library, which it says will serve the same purpose and be “[more user friendly](#)”.

As long-time users of CrowdTangle to track and analyse online misinformation campaigns, we are sceptical of this claim. We are also very concerned by the fact CrowdTangle's closure comes at a time when misinformation on social media is rife – and is bound to worsen in the lead up to the November presidential election in the United States.

So, why did Meta decide to close CrowdTangle now? And how will this affect the fight against the spread of misinformation and disinformation online?

Meta removes Facebook Groups API, disrupts social media scheduling



Ifemena Joy Okorie

Published: February 6, 2024

Share this story

Subject(s): Social Media

01-03-2024 | TECH

X nega a pesquisadores que estudam desinformação acesso a sua API

A recusa pode estar violando a nova Lei de Serviços Digitais da União Europeia – e as autoridades afirmam que estão investigando



Crédito: Kelly Sikkema/ Unsplash

Mídias Sociais e a Web

Dado diversas limitações de acesso que vem sendo impostas dia após dia, ultimamente acabamos tendo bastante trabalho para conseguir dados

Essas plataformas estão se apoiando cada vez mais em legislações que encobrem a **ausência de transparência**

Para superar essas barreiras, pesquisadores vêm desenvolvendo diferentes estratégias para coletar dados em diferentes plataformas

Mídias Sociais e a Web



Mídias Sociais e a Web

A Escala do Iceberg

O caráter do conteúdo está escalando o *iceberg*!

Normalização do "Obscuro"

O que era "obscuro" agora está nas redes sociais do dia a dia!

Isto caracteriza três tipos de estudos em conteúdos de mídias sociais online:

Mídias Sociais e a Web

Camada Superficial

Estudos sobre o comportamento social em coisas que vemos no dia a dia

- Política
- Música
- Saúde
- Marketing

Zona Cinzenta

Estudos sobre conteúdos que permeiam a ética social e a legislação

- Apostas e golpes
- Pirataria
- Marketing em conteúdo infantil

Dark Web

Estudos sobre práticas ilegais e conteúdo sensível de difícil acesso

- Pornografia infantil
- Exposição de conteúdo sensível
- Antissemitismo

Mídias Sociais e a Web



O fenômeno que você está estudando será classificado em uma dessas **três regiões**

É importante saber **qual rede social é mais propensa** para esse tipo de atividade, para que sua coleta de dados seja uma **amostragem fiel** do ecossistema que envolve seu estudo

Estratégias de coleta de dados



Utilizando APIs (*Application Programming Interface*)



Documentação Oficial

Métodos padronizados e bem documentados para extração



Dados Verdadeiros

Alta confiabilidade na veracidade da informação coletada



Performance Ótima

Esforço mínimo dentro dos limites da rede social

Atenção: Atualmente, o acesso às APIs está se tornando escasso

Estratégias de coleta de dados



Métodos de Busca e Pesquisa



search.list

Permite pesquisar vídeos, canais ou *playlists* com base em palavras-chave, localização (ex: Belo Horizonte, MG), tópicos e datas



videoCategories.list

Coleta as categorias de vídeos oficiais suportadas pelo YouTube (ex: Música, Educação, Jogos)

Estratégias de coleta de dados



Métodos de Metadados de Vídeos e Canais



videos.list

Coleta informações detalhadas de um ou mais vídeos a partir dos seus IDs (título, descrição, estatísticas de visualização, likes e duração)



channels.list

Retorna dados de um canal específico (nome, número total de inscritos, total de visualizações e data de criação)

Estratégias de coleta de dados



Métodos de Coleta de Interações



commentThreads.list

Coleta os comentários principais de um vídeo, incluindo respostas aos comentários (ideal para análise de sentimento e interação com o conteúdo)



playlistItems.list

Usado para extrair a lista completa de IDs de vídeos pertencentes a uma *playlist* pública

Estratégias de coleta de dados

HTML

Utilizando a raspagem (*scraping*) dos dados



Como funciona?

Simular o uso da ferramenta e obter o conteúdo com base no que está sendo exibido em tela



Limitações e Alertas

Processo muitas vezes lento; plataformas possuem técnicas de defesa e bloqueios

Cuidado com os termos de uso do serviço!

Estratégias de coleta de dados


<> Web Scraping: Linguagens e Ferramentas

Temos várias linguagens e ferramentas que exploram uma estrutura comum: **extração de informação do HTML** (XPath, CSS Selectors)

BeautifulSoup



Preparação
da Sopa



```
sopa =  
BeautifulSoup('doc.html', 'html.parser')
```

Estratégias de coleta de dados



Utilizando formulários online

Os formulários eletrônicos desempenham um papel crucial na interação entre pesquisadores e coleta de dados, permitindo agilidade na tomada de decisão gerencial ou acadêmica.

Benefícios

- Construção intuitiva
- Distribuição ampla
- Inteligência analítica
- Respostas simultâneas

Estratégias de coleta de dados



Google Forms

Uma ferramenta poderosa e acessível para a criação de pesquisas estruturadas, integrada ao ecossistema Google Workspace.

Acessibilidade e Versatilidade

- Gratuito para usuários individuais
- Design responsivo para celulares, tablets e PCs
- Fácil compartilhamento via link ou e-mail

Diversidade de Questões

- Múltipla escolha e caixas de seleção
- Listas suspensas e escalas lineares
- Grades de múltipla escolha e upload de arquivos

Estratégias de coleta de dados

Pontos de atenção ao se fazer pesquisa digital



Representatividade: superar o viés de obter respostas apenas de uma população hiperconectada



Interface (UX): prevenir o abandono devido a layouts confusos ou não-responsivos



Validade dos dados: evitar respostas falsas e garantir a compreensão correta (sem mediação)



Segurança e Privacidade: proteger dados sensíveis com regulações e utilizar o TCLE

Estratégias de coleta de dados

Utilizando repositórios de dados



Academic Torrents

Repositório distribuído para compartilhamento de grandes datasets e publicações acadêmicas



Kaggle Datasets

Milhares de conjuntos de dados públicos e privados para ciência de dados, visão e NLP



UCI Machine Learning Repository

Acervo clássico para IA, amplamente usado para testar algoritmos de aprendizado de máquina



Hugging Face Datasets

Principal padrão da indústria para modelos de IA generativa, focado em NLP, visão e áudio

Fluxo metodológico de aplicações



Coleta de dados

Identificação de fontes e extração primária de informações via API, repositórios, raspagem da Web ou formulários



Pré-processamento

Limpeza, normalização e remoção de ruídos dos dados, como remoção de *stopwords*



Transformação de dados

Conversão para formatos estruturados e adequados, como *word embeddings*



Aplicações de PLN

Análise de sentimentos, análise de opinião, reconhecimento de entidades e modelagem de tópicos são alguns exemplos



Visualização dos resultados

Séries temporais, gráficos, mapas de calor e *word clouds* são alguns exemplos

Ética e privacidade de dados



Restrição de Publicação

Não podemos publicar datasets com informações sensíveis e/ou atributos identificadores.



Técnicas de Anonimização

Uso de técnicas estáticas para tornar impossível a identificação de indivíduos reais.

Privacidade e Conformidade Legal

Garantia de proteção aos dados e cumprimento rigoroso de leis como a **LGPD** ou o **GDPR**.

Ética e privacidade de dados

Técnicas Estáticas de Anonimização



Supressão

Consiste em remover completamente uma informação ou uma parte dela.

Ex: Deletar colunas de identificadores diretos (Nome, CPF).



Generalização

Substitui valores exatos por categorias ou intervalos mais amplos, diminuindo a especificidade.

Ex: Idade 23, 25, 28 → Faixa 20-30 anos.



Tokenização

Substitui um identificador real por um pseudônimo, código ou "token" gerado aleatoriamente.

Garante que a identidade original não seja exposta diretamente.

Ética e privacidade de dados

Técnicas Estáticas de Anonimização



Perturbação (Adição de Ruído)

Modifica levemente os valores originais para manter propriedades estatísticas globais (médias/tendências) sem expor dados exatos.

Ex: Adicionar/subtrair dias em datas de nascimento ou pequenas % em salários.



Permutação (Data Swapping)

Embaralha valores de uma coluna entre registros. A análise do grupo permanece correta, mas o vínculo individual é desfeito.

Ex: Trocar profissões ou salários entre usuários dentro da mesma tabela.

Ponto de atenção: Existe um *trade-off* entre privacidade e utilidade. O excesso de anonimização pode invalidar o valor científico dos dados.

Dúvidas?

Créditos

Moura, Filipe A. S. Minicurso “*Coleta de Dados em Mídias Sociais Online: Oportunidades, Métodos, Limitações e muito mais*”.

Apresentado na 4ª Semana da Computação em João Monlevade (UFOP/ICEA), 2025.

Peixoto, Reginaldo; Pizolato, Williams. “*A Utilização de Formulários Eletrônicos na Coleta e Análise de Dados: algumas reflexões*”.

Revista: EaD & Tecnologias Digitais na Educação, Dourados, MS, 2025.1 – Vol. 13 – nº 18