

Análise de dados do Youtube

Especialização em Ciência de Dados

Profa. Helen de Cássia Sousa da Costa Lima



Universidade Federal
de Ouro Preto

Roteiro

1. Entendimento dos *scripts* de Análise de dados de vídeos e comentários do Youtube
2. Interpretando os resultados gerados
3. Replicando para o seu contexto

Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb

Carregando os dados coletados para Dataframes

```
# importa o arquivo e guarda em um dataframe do Pandas

dfcomentarios = pd.read_csv('/content/.../comments_info.csv' )
dfvideos = pd.read_csv('/content/.../videos_info.csv' )
dfcanaais = pd.read_csv('/content/.../channels_info.csv' )

print('Dados importados com sucesso!')
```

Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb

Limpeza: Correção e relatório de dados duplicados

```
# Remove duplicatas baseando-se no ID do canal
dfcanaiss_unico = dfcanaiss.drop_duplicates(subset="channel_id",
keep="first").reset_index(drop=True)

# Exibe o novo formato do dataframe
print_shape('Dados canais', dfcanaiss_unico)

# Relatório de duplicatas removidas
n_removidas = len(dfcanaiss) - len(dfcanaiss_unico)
ids_duplicados = dfcanaiss[dfcanaiss.duplicated(subset="channel_id",
keep="first")]["channel_id"].unique()

print(f"\nDuplicatas removidas : {n_removidas}" )
print(f"IDs duplicados encontrados: {list(ids_duplicados)}" )
```

Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb

Feature Engineering: Criando métricas de vídeo

```
def build_metrics(dfvideos, dfcanais=None, min_views=1, reference_date=None):
    # Gera colunas novas derivadas de engajamento e performance
    df = dfvideos.copy()

    # Conversão de duração (segundos para minutos)
    df["duration_min"] = df["duration_sec"] / 60

    # Cálculo da idade do vídeo (em dias)
    ref = pd.to_datetime(reference_date, utc=True) if reference_date else
    pd.Timestamp.now(tz="UTC")
    df["age_days"] = (ref - df["published_at"]).dt.total_seconds() / 86400
    df["age_days"] = df["age_days"].clip(lower=1) # evita divisão por zero
```

Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb

Feature Engineering: Criando métricas de vídeo

```
def build_metrics(dfvideos, dfcanais=None, min_views=1, reference_date=None):  
  
    # Métricas de engajamento (evita divisão por zero)  
    views = df["view_count"].replace(0, np.nan)  
    df["engagement_rate"] = (df["like_count"] + df["comment_count"]) / views  
    df["like_ratio"] = df["like_count"] / views  
    df["comment_ratio"] = df["comment_count"] / views  
    # Normalização por idade  
    df["views_per_day"] = df["view_count"] / df["age_days"]
```

Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb

Feature Engineering: Criando métricas de vídeo

```
def build_metrics(dfvideos, dfcanais=None, min_views=1, reference_date=None):  
  
    # Metadados de texto  
    df["title_len"] = df["title"].astype(str).str.len()  
    df["desc_len"] = df["description"].astype(str).str.len()  
    df["n_tags"] = df["tags"].apply(count_listlike)
```

Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb

Sumarização

```
def summarize(df):  
    metrics = [  
        "view_count", "like_count", "comment_count", "engagement_rate",  
        "like_ratio", "comment_ratio", "views_per_day", "duration_min",  
        "title_len", "desc_len", "n_tags",  
    ]  
    metrics = [m for m in metrics if m in df.columns]  
    print("=== Resumo estatístico ===" )  
    print(df[metrics].describe().T)  
    print("\n=== Top 10 vídeos por taxa de engajamento ===" )  
    cols = [c for c in ["title", "view_count", "engagement_rate", "views_per_day"] if c in  
df.columns]  
    print(df.sort_values("engagement_rate", ascending=False)[cols].head(10))  
    return df[metrics].describe().T
```

Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb

Sumarização

=== Resumo estatístico ===

	count	mean	std	min	25%	50%	75%	max
view_count	407.0	52305.587224	99144.848703	59.000000	7194.500000	19189.000000	57397.000000	943905.000000
like_count	407.0	1493.633907	2608.857767	0.000000	191.000000	568.000000	1613.000000	21478.000000
comment_count	407.0	104.916462	199.830625	1.000000	11.000000	37.000000	99.500000	1799.000000
engagement_rate	407.0	0.038632	0.021022	0.000522	0.024278	0.034814	0.050774	0.120219
like_ratio	407.0	0.035755	0.019516	0.000000	0.022895	0.031876	0.047677	0.113803
comment_ratio	407.0	0.002877	0.003084	0.000053	0.001024	0.002093	0.003605	0.026490
views_per_day	407.0	157.827670	256.384024	0.463167	21.760973	67.002100	188.423389	2168.651505
duration_min	407.0	11.211507	12.203009	0.083333	1.000000	8.083333	18.700000	95.866667
title_len	407.0	68.007371	21.107686	18.000000	53.000000	68.000000	86.000000	100.000000
desc_len	407.0	884.449631	1067.328626	3.000000	124.500000	516.000000	1222.000000	4998.000000
n_tags	407.0	12.243243	12.962519	0.000000	0.000000	11.000000	21.000000	72.000000

Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb

Sumarização


=== Top 10 vídeos por taxa de engajamento ===

	title	view_count	engagement_rate	views_per_day
359	DETALHES e PERFORMANCE na PISTA do ABARTH FAST...	366	0.120219	0.463056
243	O PAI DO FASTBACK que A FIAT NUNCA ASSUMIU! Ou...	54814	0.115536	105.994745
303	Primeiras Impressões Fiat Fastback Audace T200...	3071	0.111039	4.734742
6	POV: Dirigindo o FIAT FASTBACK sob chuva forte...	566	0.107774	22.484582
397	Avaliação do Fastback pelos consumidores mais ...	1107	0.101174	1.671595
21	Autos que ODIÓ pt. 2 - Fiat Fastback	66864	0.097182	900.621928
46	Avaliação Fiat Fastback Impetus Hybrid - MUITO...	55253	0.093877	408.690017
26	FASTBACK ABARTH 2026 - SUV Esportivo Que Super...	11330	0.093733	166.290247
93	FASTBACK ABARTH: a Fiat fez o dever de casa	11223	0.092310	60.520079
48	Fastback 1.0 Turbo Pesado na Estrada: Teste Re...	1883	0.087626	15.373374

Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb


Visualizações: *Cumulative Distribution Function (CDF)*



Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb


Visualizações: Matriz de correlação



Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb


Visualizações: Boxplot



Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb


Visualizações: Gráfico de dispersão (scatter plot)



Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb


Visualizações: Análise temporal (Barras)



Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb


Visualizações: Análise temporal (Barras e eixos duplos)



Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb


Visualizações: Análise temporal (Linhas) - mediana de views por vídeo



Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb

Visualizações: Análise temporal (Linhas) - mediana de views/dia por vídeo



Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb

Visualizações: Análise temporal (série mensal)



Script de Análise - YouTube

analise_dados_youtube_aula2.ipynb

Comparações por grupo

```
=== engagement_rate por caption ===  
      median      mean  count  
caption  
False    0.034814  0.038663   405  
True     0.032340  0.032340     2
```

```
=== engagement_rate por definition ===  
      median      mean  count  
definition  
sd        0.038719  0.038719     2  
hd        0.034814  0.038631   405
```

```
category_id  
2          0.036290  0.039460   332  
19         0.035878  0.035878     2  
24         0.030993  0.037371    12  
25         0.030911  0.030911     1  
22         0.029066  0.036485    54  
17         0.024387  0.024387     2  
20         0.019023  0.019023     2  
23         0.007046  0.007046     2
```

Script de Análise - YouTube

analise_comentarios_Youtube_aula2.ipynb

Feature Engineering: limpeza e novas métricas de comentários

```
# Numéricos
df["like_count"] = pd.to_numeric(df["like_count"], errors="coerce")

# is_reply é convertido para numérico, facilitando sumarização
df["is_reply"] = df["is_reply"].astype(bool).astype(int)

# Comprimento do texto do comentário
df["comment_len"] = df["comment"].astype(str).str.len()
df["comment_words"] = df["comment"].astype(str).str.split().apply(len)
```

Script de Análise - YouTube

analise_comentarios_Youtube_aula2.ipynb

Criando séries mensais de comentários

```
monthly = (  
    df.set_index("published_at")  
      .resample("ME")  
      .agg(  
          n_comentarios=( "comment_id", "count"),  
          comentaristas_unicos=( "author_channel_id", "nunique"),  
          likes_totais=( "like_count", "sum"),  
          pct_respostas=( "is_reply", "mean"),  
      )  
)  
monthly.head(24)
```

Script de Análise - YouTube

analise_comentarios_Youtube_aula2.ipynb


Visualizações de séries mensais de comentários



Script de Análise - YouTube

analise_comentarios_Youtube_aula2.ipynb


Visualizações de séries mensais de comentários



Script de Análise - YouTube

analise_comentarios_Youtube_aula2.ipynb



Visualizações de séries mensais de comentários



Script de Análise - YouTube

analise_comentarios_Youtube_aula2.ipynb


Visualizações de séries mensais de comentários



Script de Análise - YouTube

analise_comentarios_Youtube_aula2.ipynb

Visualização: número de palavras por comentário



Script de Análise - YouTube

analise_comentarios_Youtube_aula2.ipynb

Top usuários mais ativos

		n_comentarios	likes_totais
author	author_channel_id		
@MotoristaSincero10	UC-BdGoOqh8Zkpy3fklKg7hA	439	609
@CanalGTAutos	UCT2J6PZM2W1ZI2kcBcFEe9A	398	270
@L1PEX	UCpRAM8vmxUYQcV2Dku7y8Eg	206	33
@jeandealmeida9927	UCBbAwqU9EcOoUqIO34nPOTw	162	102
@CanaldoBlogdoCadeirante	UCCiXI5sII_gC5PY-BaLza7A	129	122
@LucasAbriata	UCOypnH-5DDOh1WXHJxm_t1A	124	1641
@PatriciaAlbani	UCBtSp6oNEiZeNylWL15JWzg	122	42
@mycarsbr	UCLFbmb6wLvCH42tVggh0KAA	102	154
@sergiofeo686	UCRMJTr_B58xmF7M5JzUi2lg	88	40
@MatiasAnticoTV	UCd61IERUuGODiG08h3_30JA	83	278

Script de Análise - YouTube

analise_comentarios_Youtube_aula2.ipynb

Top comentários mai curtidos

author	like_count	comment
@caio5250	1811	Entrega o básico, brasileiro que se acostumou com qualquer lixo. Pagar 115k nisso aí é ultrajante
@felipec8868	1608	Cheguei mais rápido do que a Volkswagen no ouvindo da UOL
@lucasoliveirasx	1407	Como fazer 300 pila por dia! 🔥
@jotasiq	1326	Não tem ACC Não tem 6 airbags Não tem freio a disco na traseira Não tem assistente/corretor de faixa Não tem assistente de ponto cego Não tem câmera 360. Tem plástico....
@gustavocarneiros02	994	Peguei um desse essa semana e estou 100% satisfeito. Além de ser muito bonito é um carro que dá prazer em dirigir
@PabloPérez-o7u4b	944	Poner a un Youtuber en una "lista negra" solo por dar su opinión es literalmente pegarte un tiro en el pie. Nosotros miramos el canal de Lucas porque queremos escuchar su opinión, ya sea buena o mala, sobre determinado auto. E youtubers. Media pila Stellantis.
@rafaellopez2382	795	La cara de la concesionaria que le prestó el auto: -_-
@marcosdias2454	794	O cara mostrando um desempenho absurdo de um motor 1.0 e a turma especialista achando fraco rsrsrs
@thor_nardo	758	Se tem Lucão com uniforme de round 6, tem like!
@HobbiesDaVida	689	Comprei esse carro por 119.990 com o pacote smart drive, que adiciona camera de ré, chave presencial, etc. Acho que valeu muito a pena e estou feliz com minha aquisição
@igoruchoa503	673	VW chora toda vez que o Lucão solta um vídeo 😂😂
@capitao_libertario	647	Esse camarada tem 200% mais carisma pra apresentar do que o resto do pessoal. Se ele abrir um canal dele mesmo vai bombar.
@LucasAbriata	621	Datos del backstage de este video: Anabella de El Cero Km (amigos de Twitter, para los que me siguen por ahí) me dijo que quería que hicieramos una colaboración. Yo le dije que a ella no le iba a cobrar si me conseguía un auto (que cuesta es un gran producto, especialmente en comparación a algunas de las basuras que siguen haciendo los de Stellantis (te miro a vos C3). Gracias a todos por ver el video y un abrazo grande!
@LucasAbriata	621	Datos del backstage de este video: Anabella de El Cero Km (amigos de Twitter, para los que me siguen por ahí) me dijo que quería que hicieramos una colaboración. Yo le dije que a ella no le iba a cobrar si me conseguía un auto (que cuesta es un gran producto, especialmente en comparación a algunas de las basuras que siguen haciendo los de Stellantis (te miro a vos C3). Gracias a todos por ver el video y un abrazo grande!
@brunogomezsilva1933	571	Tem q comprar carro bonito sim Pra quando vc lembrar do boleto, olhar pro carro e achar q valeu a pena kkkkkk

Script de Análise - YouTube

analise_comentarios_Youtube_aula2.ipynb

Co-ocorrência: palavras que mais aparecem junto a um termo de interesse

	palavra	frequencia
0	disco	567
1	tambor	468
2	traseira	205
3	rodas	200
4	traseiro	122
5	mão	91
6	freio	90
7	eletrônico	88
8	mesmo	66
9	airbags	62
10	mil	60


	2-grama	frequencia
0	freio disco	492
1	freio tambor	376
2	freio mão	85
3	freio estacionamento	52
4	freio traseiro	44
5	esportivo freio	27
6	airbags freio	24
7	colocar freio	21
8	nem freio	20
9	disco freio	20
10	falta freio	19
11	freio eletrônico	18

	3-grama	frequencia
0	freio disco rodas	128
1	freio disco traseira	81
2	freio tambor traseira	58
3	freio disco traseiro	47
4	freio estacionamento eletrônico	33
5	freio mão eletrônico	28
6	freio disco quatro	28
7	freio traseiro tambor	22
8	esportivo freio tambor	20
9	nem freio disco	18
10	colocar freio disco	17
11	airbags freio disco	15
12	falta freio disco	15

Script de Análise - YouTube

analise_comentarios_Youtube_aula2.ipynb

Co-ocorrência: palavras que mais aparecem junto a um termo de interesse




Script de Análise - YouTube

analise_comentarios_Youtube_aula2.ipynb

Análise de tópicos

Topic Word Scores




Script de Análise - YouTube

analise_comentarios_Youtube_aula2.ipynb

Análise de tópicos


Topics over Time



Script de Análise - YouTube

analise_comentarios_Youtube_aula2.ipynb

Análise de sentimentos multi rótulos



Dúvidas?

Créditos

Parte do código fonte gerado para as análises utilizou o Claude 4.8 Opus (Anthropic, 2026).

Matheus Azevedo. Pipeline de coleta de dados do Reddit.

Link: <https://www.kaggle.com/code/matsa000/pipeline-de-coleta-de-dados-do-reddit>. Acessado em 17 de junho de 2026.