



Aluno: Leonardo Isaac Silva Flores

Domínio: www.gov.br/saude - Tema: Estratégia Saúde da Família

Qualidade dos dados e uso em RAG

O corpus foi coletado do portal do Ministério da Saúde a partir de páginas sobre a Estratégia Saúde da Família. O conteúdo é em HTML estático, o que facilita a extração. Após filtrar as tags de navegação, o texto de cada página ficou focado no assunto principal, sem muito “lixo”.

Para um pipeline de RAG, algumas características do corpus são importantes. Cada registro tem a URL de origem, o que permite rastrear a fonte de cada trecho na hora de montar a resposta. O texto já está limpo o suficiente para ser dividido em blocos menores e indexado. O tema é bem delimitado, o que reduz a chance de recuperar trechos fora de contexto.

O ponto que mais limitaria a qualidade das respostas é o volume. Com 5.343 palavras distribuídas em 8 páginas, algumas perguntas sobre o tema podem não encontrar conteúdo suficiente no corpus. Páginas menores, como a de saúde bucal com cerca de 390 palavras, gerariam no máximo um único trecho de 300 palavras, o que pode ser pouco contexto para responder bem. Aumentar a profundidade de coleta para 1 nível ou incluir subpáginas de cada tema resolveria essa limitação sem comprometer a qualidade do texto já coletado.

Problema de coleta encontrado e como foi resolvido

Durante os testes, várias URLs do gov.br/saude retornavam o mesmo conteúdo, independente da página acessada. O título e o texto eram idênticos em endereços que deveriam ser diferentes. Isso acontece porque parte do site carrega o conteúdo via JavaScript no navegador, e o HTML que chega na requisição não tem o texto real.

Para contornar, testei cada URL antes de incluir no corpus: baixei a página, conferi se o título era diferente das outras e se tinha mais de 400 palavras de conteúdo. Só ficaram as 8 páginas que passaram nesse critério, evitando duplicatas no corpus.

Referências:

www.gov.br/saude

www.gov.br

www.iana.org

IDE AI: <https://kiro.dev/> prompt: “validar resolução dos exercícios, e indicar possíveis inconsistências conforme o enunciado”