



Universidade Federal de Ouro Preto
Instituto de Ciências Exatas e Aplicadas



CDD104 - Recuperação da Informação na Web e Redes Sociais

Professora: Helen De Cassia Sousa Da Costa Lima

Atividade – 3

Aluno: Leonardo Isaac Silva Flores

Domínio: www.gov.br/saude - Tema: Estratégia Saúde da Família

Exercício 1

Profundidade 0: 1 página níveis [0] profundidade 1: 12 páginas níveis [0, 1]

Profundidade 2: 40 páginas níveis [0, 1, 2] (atingiu o teto) Resposta: A cada nível o número de páginas cresce porque cada página visitada tem vários links para outras páginas do mesmo site. Com profundidade 0 só a semente é coletada. Com profundidade 1 todos os links dela são visitados. Com profundidade 2 os links de cada uma dessas páginas também são visitados, multiplicando o volume rapidamente. e. Para um site grande como gov.br isso esgotou o teto de 40 páginas ainda no nível 2. Sem esse limite o crawl poderia rodar por horas.

Exercício 2

Permitido <https://www.gov.br/saude/pt-br/composicao/saps/esf>

Permitido <https://www.iso.org/standard/81230.html>

Permitido <https://www.iana.org/help/example-domains>

Se um site bloqueia uma rota no robots.txt, o scraper deve registrar o bloqueio e pular a URL sem tentar acessar de outra forma. Se o servidor retornar erro 403, o comportamento é o mesmo: registrar o erro e seguir em frente. Em nenhum caso o scraper deve forçar o acesso a uma URL que foi bloqueada.

Exercício 3

Primeiro registro - página ESF principal:

N de links: 10 - N de figuras: 3

Trecho: "A Estratégia Saúde da Família coloca a saúde no centro das necessidades da pessoa, da família e do território..."

O texto ficou razoavelmente limpo. O seletor "main" remove a maior parte dos menus e barras de navegação, deixando o corpo principal da página. Alguns itens de rodapé ainda ficaram em certos registros e foram removidos manualmente depois da coleta. Isso mostra que o isolamento automático resolve boa parte do problema, mas pode precisar de ajuste por site. Páginas do visualizador OBP da ISO retornam texto vazio porque o conteúdo é carregado por Javascript, fora do alcance do scraper estático.

Exercício 4

Com max_por_dominio = 3 :

3 www.gov.br

3 www.iana.org

Com max_por_dominio=15:

15 www.gov.br

10 www.iana.org (site menor, menos páginas)

Sem o teto por domínio, o primeiro site com muitos links internos ocuparia todas as vagas do corpus e os outros domínios nunca seriam visitados. Com o teto, cada site contribui com no máximo N páginas, garantindo variedade de fontes no corpus mesmo quando um site tem muito mais links internos do que outro.

Exercício 5

Resultados: /manual_acs.pdf - PDF = OK (os dois)

gov.br/esf - PDF = NOK (os dois)

/content - PDF = OK com HEAD, NOK sem HEAD

/download?attachment - PDF = NOK (os dois)

Checar só a extensão .pdf não basta porque servidores podem servir arquivos PDF por qualquer rota sem extensão no caminho. Exemplos comuns são URLs que terminam em /content ou /download. Sem a verificação HEAD, o scraper tentaria baixar esses arquivos como se fossem HTML e geraria registros vazios. A verificação do Content-Type via requisição HEAD confirma o tipo real do arquivo antes de tentar coletar.

Exercício 6

Resultados:

Tamanho 300: 23 trechos no corpus

Tamanho 800: 10 trechos no corpus

Tamanho 1500: 8 trechos no corpus

Exemplo (tamanho 800): fonte: <https://www.gov.br/saude/pt-br/composicao/saps/esf>

Trechos muito pequenos cortam o texto no meio do assunto, tirando o contexto necessário para responder bem uma pergunta. Trechos muito grandes incluem partes sem relação com a pergunta, piorando a resposta. O tamanho 800 ficou adequado para o corpus coletado porque a maioria das páginas tem entre 400 e 1300 palavras. Guardar URL junto com cada trecho é necessário para que o usuário saiba de onde veio a informação e possa verificar na fonte original.