

Coleta de Dados estática na Web

Especialização em Ciência de Dados

Profa. Helen de Cássia Sousa da Costa Lima



Universidade Federal
de Ouro Preto

O caminho de hoje

Da coleta ao RAG: cinco decisões de engenharia enfrentadas num *web scraper* de produção

1



Fundamentos

API, estático ou dinâmico?
HTTP e a árvore HTML.

2



Ética & lei

robots.txt, rate limiting,
User-Agent, LGPD.

3



O crawler

BFS, profundidade,
deduplicação,
salvaguardas.

4



Qualidade

Conteúdo central, figuras,
PDFs disfarçados.

5



Rumo ao RAG

Do JSON coletado aos
chunks recuperáveis.

Três caminhos para obter dados

http



API oficial

PREFIRA

Quando existe, é sempre a 1ª escolha. Estruturado, estável, permitido.



Scraping estático

FOCO DA AULA

O HTML já vem pronto na resposta.
requests + BeautifulSoup.



Scraping dinâmico


MAIS CUSTOSO

Conteúdo montado por JavaScript.
Exige Selenium / Playwright. Ex.: o visualizador OBP da ISO volta vazio no estático.

Árvore DOM

http

```
<html>
<body>
  <div id="page">
    <h1 id="header">List</h1>
    <h2>Buy groceries</h2>
    <ul>
      <li id="one" class="hot"><em>fresh</em> figs</li>
      <li id="two" class="hot">pine nuts</li>
      <li id="three" class="hot">honey</li>
      <li id="four">balsamic vinegar</li>
    </ul>
    <script src="js/list.js"></script>
  </div>
</body>
</html>
```



Conseguir não é ter permissão

Ética e legalidade da coleta

robots.txt

O site declara o que robôs podem acessar. Respeitar é regra, não cortesia.

Rate limiting

Pausar entre requisições (`time.sleep`) protege o servidor e evita bloqueio.

User-Agent honesto

Identificar o robô — não se passar por navegador.

Termos & LGPD

Direitos autorais e dados pessoais. “É legal?” depende — e do quê.



No corpus real: alguns sites bloqueiam rotas no robots.txt e outros retornam 403. O scraper registra e segue — **nunca força.**

Coletar o miolo, não a moldura

Menus, rodapés e barras laterais repetem-se em cada página — viram ruído no corpus




Estratégia de isolamento

- Remover tags estruturais: nav, header, footer, aside
- Remover blocos por padrões de id / class
- Selecionar a região principal: main, article
- Coletar figuras de dentro do miolo (SVG e lazy-load)

Por que importa para RAG: menu repetido em todo chunk polui os embeddings e degrada a recuperação.

O crawler: busca em largura

Uma fila percorre as páginas nível a nível, com deduplicação e limites



Fila (deque)

Ordem de chegada → cobertura previsível por nível.

visitadas (set)

Evita repetir páginas e cair em ciclos.

Profundidade

0 = sementes, 1, 2... Ilimitada é perigosa.

Salvaguardas

Teto global, teto por domínio, timeout.



“Ficou rodando por mais de uma hora”

O sintoma

- 8 sementes de sites grandes (NIST, ISO, OMS...)
- profundidade ilimitada
- delay de 1s entre páginas

→ **crawl praticamente infinito**

A correção

- profundidade = 1 (cobrir sem explodir)
- teto global + teto por domínio
- delay 0,5s + timeout 10s
- feedback de progresso ao vivo



MOMENTO DE DECISÃO #2

Quando a heurística erra

O filtro agressivo demais

O padrão “menu” removía tudo com 'menu' no nome.

Mas tekup-service-menu era navegação entre subpáginas — conteúdo útil!

Heurística exige inspeção e ajuste. Não há filtro universal.



PDFs disfarçados

Nem todo PDF termina em .pdf:

.../bitstreams/.../content (OMS)

.../download?attachment (genérico)

Deteccção em 2 camadas: pista na URL + HEAD real.

4

PDFs (só .pdf)




5

PDFs detectados

+1 disfarçado que passaria batido

Da coleta ao RAG

O scraping produz a matéria-prima. A qualidade do RAG é limitada pela qualidade da coleta.



A saída JSON, pensada para RAG

url	proveniência — permite citar a fonte	texto	vira os chunks recuperáveis
titulo	rótulo e contexto do trecho	pai / profundidade	rastreabilidade do caminho

Cinco decisões, um corpus confiável

- 1 Escolher a abordagem certa (estático, aqui)
- 2 Respeitar limites éticos e legais
- 3 Controlar escopo: profundidade e salvaguardas
- 4 Isolar o conteúdo central, filtrar PDFs
- 5 Estruturar a saída para o pipeline de RAG



Agora é com vocês

Prática acompanhada
no notebook do estudo de caso

Exercícios guiados

Dúvidas?

Créditos

Parte do código fonte gerado nesta aula utilizou o Claude 4.8 Opus (Anthropic, 2026).