

Lista de Exercicios - Coleta de Dados na Web

Disciplina: Recuperacao da Informacao na Web e Redes Sociais - UFOP

Aluno: Leonardo Flores

Dominio: www.gov.br/saude | Tema: Estrategia Saude da Familia

Exercicio 1 - Ajustando a profundidade [Guiado]

Tarefa: rodar a coleta com profundidade_max igual a 0, 1 e 2 usando a pagina principal da ESF como semente.

Resultados:

profundidade 0: 1 pagina niveis [0]

profundidade 1: 12 paginas niveis [0, 1]

profundidade 2: 40 paginas niveis [0, 1, 2] (atingiu o teto)

Resposta:

A cada nivel o numero de paginas cresce porque cada pagina visitada tem varios links para outras paginas do mesmo site. Com profundidade 0 so a semente e coletada. Com profundidade 1 todos os links dela sao visitados. Com profundidade 2 os links de cada uma dessas paginas tambem sao visitados, multiplicando o volume rapidamente. Para um site grande como gov.br isso esgotou o teto de 40 paginas ainda no nivel 2. Sem esse limite o crawl poderia rodar por horas.

Exercicio 2 - Lendo o robots.txt [Guiado]

Tarefa: testar pode_acessar em tres URLs de dominios diferentes.

Resultados:

permitido <https://www.gov.br/saude/pt-br/composicao/saps/esf>

permitido <https://www.iso.org/standard/81230.html>

permitido <https://www.iana.org/help/example-domains>

Resposta:

Se um site bloqueia uma rota no robots.txt, o scraper deve registrar o bloqueio e pular a URL sem tentar acessar de outra forma. Se o servidor retornar erro 403, o comportamento e o mesmo: registrar o erro e seguir em frente. Em nenhum caso o scraper deve forcar o acesso a uma URL que foi bloqueada.

Exercicio 3 - Interpretando o conteudo coletado [Intermediario]

Tarefa: inspecionar o primeiro registro do corpus e avaliar a qualidade do texto extraido.

Primeiro registro - pagina ESF principal:

N de links: 10 | N de figuras: 3

Trecho: "A Estrategia Saude da Familia coloca a saude no centro das necessidades da pessoa, da familia e do territorio..."

Resposta:

O texto ficou razoavelmente limpo. O seletor "main" remove a maior parte dos menus e barras de navegacao, deixando o corpo principal da pagina. Alguns itens de rodape ainda ficaram em certos registros e foram removidos manualmente depois da coleta. Isso mostra que o isolamento automatico resolve boa parte do problema mas pode precisar de ajuste por site. Paginas do visualizador OBP da ISO retornam texto vazio porque o conteudo e carregado por JavaScript, fora do alcance do scraper estatico.

Exercicio 4 - Teto por dominio [Intermediario]

Tarefa: rodar com `max_por_dominio=3` e `max_por_dominio=15` usando sementes de dois dominios.

Com `max_por_dominio=3`:

3 `www.gov.br`
3 `www.iana.org`

Com `max_por_dominio=15`:

15 `www.gov.br`
10 `www.iana.org` (site menor, menos paginas)

Resposta:

Sem o teto por dominio, o primeiro site com muitos links internos ocuparia todas as vagas do corpus e os outros dominios nunca seriam visitados. Com o teto, cada site contribui com no maximo N paginas, garantindo variedade de fontes no corpus mesmo quando um site tem muito mais links internos do que outro.

Exercicio 5 - Cacando PDFs disfarcados [Extensao]

Tarefa: comparar `verificar_tipo_real=True` e `False` para identificar PDFs que passariam sem a verificacao HEAD.

Resultados:

`/manual_acs.pdf` -> PDF=True (os dois)
`gov.br/.../esf` -> PDF=False (os dois)
`/.../content` -> PDF=True com HEAD, False sem HEAD
`/.../download?attachment` -> PDF=False (os dois)

Resposta:

Checar so a extensao `.pdf` nao basta porque servidores podem servir arquivos PDF por qualquer rota sem extensao no caminho. Exemplos comuns sao URLs que terminam em `/content` ou `/download`. Sem a verificacao HEAD, o scraper tentaria baixar esses arquivos como se fossem HTML e geraria registros vazios. A verificacao do Content-Type via requisicao HEAD confirma o tipo real do arquivo antes de tentar coletar.

Exercicio 6 - Do corpus ao trecho [Extensao]

Tarefa: aplicar `chunk_simples` com tamanhos 300, 800 e 1500 palavras e guardar a URL de origem junto com cada trecho.

Resultados:

tamanho 300: 23 trechos no corpus
tamanho 800: 10 trechos no corpus
tamanho 1500: 8 trechos no corpus

Exemplo (tamanho 800):

fonte: `https://www.gov.br/saude/pt-br/composicao/saps/esf`

Resposta:

Trechos muito pequenos cortam o texto no meio do assunto, tirando o contexto necessario para responder bem uma

Exercícios - Coleta de Dados na Web

pergunta. Trechos muito grandes incluem partes sem relação com a pergunta, piorando a resposta. O tamanho 800 ficou adequado para o corpus coletado porque a maioria das páginas tem entre 400 e 1300 palavras. Guardar a URL junto com cada trecho é necessário para que o usuário saiba de onde veio a informação e possa verificar na fonte original.

Corpus coletado - resumo

Dominio: www.gov.br/saude

Paginas coletadas: 8

Total de palavras: 5343

Media por pagina: 667 palavras

Total de figuras: 20

Robots.txt verificado antes da coleta. Todas as paginas estao permitidas.

Delay entre requisicoes: 0,5 segundo.

Paginas:

Estrategia Saude da Familia (612 palavras)

gov.br/saude/pt-br/composicao/saps/esf

Equipe de Saude da Familia (449 palavras)

gov.br/saude/pt-br/composicao/saps/esf/equipe-saude-da-familia

Equipes de Saude da Familia Ribeirinhas (ESFR) (1314 palavras)

gov.br/saude/pt-br/composicao/saps/esf/esfr

Consultorio na Rua (607 palavras)

gov.br/saude/pt-br/composicao/saps/esf/consultorio-na-rua

Equipe de Atencao Primaria (452 palavras)

gov.br/saude/pt-br/composicao/saps/esf/eap

Perguntas Frequentes (FAQ) (696 palavras)

gov.br/saude/pt-br/composicao/saps/esf/faq

Saude bucal na Atencao Primaria a Saude (388 palavras)

gov.br/saude/pt-br/composicao/saps/brasil-sorridente/saude-bucal-na-aps

Sobre a PNAISP (825 palavras)

gov.br/saude/pt-br/composicao/saps/pnaisp/sobre-a-pnaisp

Qualidade dos dados e uso em RAG

As paginas coletadas sao do portal do Ministerio da Saude e tem conteudo em HTML estatico, o que facilita a extracao de texto. O scraper filtra as tags de navegacao (nav, header, footer) antes de salvar o conteudo, entao o que fica em cada registro corresponde ao corpo principal da pagina. A qualidade do texto variou: paginas como a das Equipes Ribeirinhas ficaram com mais de 1.300 palavras de conteudo bem estruturado, enquanto a pagina de saude bucal ficou com cerca de 390 palavras. Ainda sobraram trechos de rodape em alguns registros (links da ouvidoria e textos sobre a Vaccine Safety Net), que foram removidos manualmente depois da coleta automatica.

Para um sistema de perguntas e respostas (RAG), o corpus esta em boas condicoes para testes iniciais. O conteudo cobre um tema especifico (a Estrategia Saude da Familia), todas as paginas tem a URL de origem registrada, e o texto ja esta limpo o suficiente para ser quebrado em trechos e buscado. O ponto fraco e o volume: com 5.343 palavras no total o corpus e pequeno para cobrir o tema de forma completa. Ampliar a coleta com mais subpaginas ou aumentar a profundidade para 1 resolveria isso.

Problema de coleta encontrado e como foi resolvido

Durante a selecao das paginas, varias URLs do gov.br/saude devolviam o mesmo conteudo HTML independente do caminho acessado. O titulo e o texto eram iguais em paginas que deveriam ser diferentes, todas com cerca de 700 caracteres de texto. Isso acontece porque parte do site usa JavaScript para montar o conteudo no navegador, e a resposta HTTP so tem um HTML generico sem o texto real da pagina.

Para resolver, cada URL foi testada manualmente antes de entrar no corpus: fiz uma requisicao simples, extraiu o titulo da pagina e contei quantas palavras tinham no texto limpo. So ficaram as 8 URLs que tinham titulo diferente das outras e mais de 400 palavras de conteudo. Com isso o corpus final ficou com 8 paginas distintas, sem registros duplicados disfarados de URLs diferentes.