

A escada da recuperação na Web

Especialização em Ciência de Dados

Profa. Helen de Cássia Sousa da Costa Lima



UFOP

Universidade Federal
de Ouro Preto



Lembram da ISO?

O que aconteceu na anterior?

- As normas da ISO no visualizador OBP voltaram vazias na coleta estática
- **Requests** só recebia a casca de HTML

→ o texto vinha por JavaScript

A pergunta em aberto

- E quando o conteúdo só existe depois do JavaScript rodar?
- A **reviravolta**: antes do Selenium, quase sempre a resposta é a API.

A escada da recuperação na Web

Desça de cima para baixo e pare no primeiro degrau que resolver o seu problema de coleta

1



API oficial

Estruturada, estável,
permitida.
Sempre a 1ª escolha.

2



Dados abertos

Arquivos prontos:
CSV, JSON, [OData](#),
portais de dados.

3



Scraping estático

Conteúdo no HTML,
sem API, com
BeautifulSoup.

4



Scraping dinâmico

Último recurso:
JavaScript ou
interação, com
Selenium.

5



Regra de ouro

**Subir um degrau
desnecessário é o
anti-padrão**
(raspar aquilo que
tem API).



A porta da frente: a API do Banco Central

O que a API entrega

JSON estruturado — sem parsear HTML.

Estável: não quebra com mudança de layout.

Permitida, documentada e sem custo de navegador.

</> PTAX e Focus via OData

```
base = olinda.bcb.gov.br/.../CotacaoDolarPeriodo
```

```
params = { $format: json,  
           $select: cotacaoVenda,... }
```

```
requests.get(base, params) — câmbio e inflação prontos.
```

câmbio + inflação → **100%** estruturado e legal

*Se a aula terminasse aqui,
já teríamos dados reais.*

Procure a porta da frente

A habilidade de recuperação mais subestimada: ler a documentação

1 · Portal de dados abertos?

dadosabertos.bcb.gov.br · dados.gov.br — comece por aqui.

2 · API ou CSV/JSON pronto?

Se há arquivo para baixar, pare — não desça a escada.

3 · Os termos permitem?

Acesso automatizado autorizado? Permissão é parte da recuperação.

Ler é parte do trabalho

Ler a documentação não é passo opcional — é recuperação.



Degrau 2: muitas fontes públicas oferecem dados abertos — ler a doc evita raspar à toa. A porta da frente quase sempre existe — **basta procurar.**

O navegador entra em cena

http



requests sozinho

NÃO BASTA

Baixa o HTML cru e NÃO executa JavaScript. Se o dado é montado no navegador, ele não está lá — é a página vazia da ISO que vimos na última aula.



Selenium

O NAVEGADOR

Controla um navegador real, executa o JavaScript (inclusive AJAX) e entrega o DOM renderizado. Permite interagir: preencher, clicar, submeter e etc.



Esperas explícitas

O QUE FALTA

WebDriverWait em vez de time.sleep cego: aguarde o elemento certo aparecer, não um número fixo de segundos.



Espera cega vs. espera explícita

✗ Espera cega

```
driver.get(url)
time.sleep(5)
el = driver.find_element(...) → desperdiça tempo ou falha.
```



✓ Espera explícita

```
WebDriverWait(driver, 10).until(
    EC.presence_of_element_located(
        (By.CSS_SELECTOR, #preco)))
```

Aguarda o elemento certo, até um limite. Robusto e eficiente.

sleep cego frágil



wait robusto

*Espera pelo que precisa aparecer,
não por um número fixo.*

Monitorar uma página

http



Snapshot periódico

HISTÓRICO • grau 4

Lê o preço do Bitcoin (TradingView) por Selenium e grava TODO o histórico. Melhor para reconstruir a série.



Detecção de mudança

ALERTAS • grau 4

Mesma sessão Selenium: compara com a leitura anterior e só registra quando muda. Ideal para alertas.



Sessão ao vivo

TEMPO REAL • grau 4

Mesma sessão, mas relê o preço ao vivo — sem gravar nem filtrar. A mais fiel ao tempo real e a mais detectável pelo servidor.

O Selenium eleva a barra ética

Quanto mais alto o degrau, mais responsabilidade ao usá-lo

Termos de uso vs. robots.txt

Os Termos podem proibir o que o robots.txt permitiria.
Lê-los é parte da recuperação.

“Parecer humano” pesa

Contornar proteção anti-bot é decisão ética, não só técnica.

Rate limiting é sobrevivência

Espaçar requisições evita detecção e bloqueio — além de cortesia.

A ordem da escada é ética

Quanto mais alto o degrau (prioridade 1), menos se sobrecarrega o servidor e mais se respeita a intenção da fonte.



O próprio Selenium averte: conheça os termos do site — alguns não permitem automação e até bloqueiam o Selenium — **respeite isso.**

A escada preenchida

- 1 API — Câmbio e Focus (Olinda / Banco Central)
- 2 Dados abertos — Portal dadosabertos.bcb.gov.br
- 3 Estático — requests + BeautifulSoup
- 4 Dinâmico — Selenium + esperas + monitor
- 5 Ética — a ordem da escada minimiza o impacto



A lição que fica

Devemos saber **QUANDO**
usar cada degrau — e quando não usar.

Quatro degraus, uma decisão consciente

- 1 Comece pela API — quase sempre ela existe
- 2 Procure dados abertos antes de raspar
- 3 Use *scraping* estático quando o HTML basta (rápido)
- 4 Selenium só em último recurso — com esperas
- 5 Suba a escada com responsabilidade ética



Agora é com vocês

Prática acompanhada no
notebook do estudo de caso:
câmbio (PTAX), Focus e monitor

Exercícios guiados

Dúvidas?

Créditos

Parte do código fonte gerado nesta aula utilizou o Claude 4.8 Opus (Anthropic, 2026).