

Resolução dos Exercícios — Escada da Recuperação na Web

Disciplina: Recuperação de Informação na Web e Redes Sociais

Aula 5: Da API ao Selenium — degraus 1 ao 4

ok

Exercício 1 — Expectativas do Focus para a Selic (Degrau 1 — API)

Recuperar via API Olinda as expectativas do Focus para a **Selic** e montar um DataFrame com os **10 meses mais recentes**.

```
df_selic = buscar_focus('Selic', meses=10)

print('Indicador :', df_selic['Indicador'].iloc[0])
print('Ano-ref   :', df_selic['DataReferencia'].iloc[0])
print('Registros :', len(df_selic), 'meses')
print('Período   :', df_selic['mes'].min().strftime('%b/%Y'),
      'a', df_selic['mes'].max().strftime('%b/%Y'))
print()
df_selic[['mes', 'Mediana', 'Media', 'DesvioPadrao']]
```

Indicador : Selic
Ano-ref : 2026
Registros : 10 meses
Período : Oct/2025 a Jul/2026

	mes	Mediana	Media	DesvioPadrao
0	2025-10-01	12.25	12.1750	0.6779
1	2025-11-01	12.00	12.1405	0.5770
2	2025-12-01	12.25	12.2225	0.6313
3	2026-01-01	12.25	12.2617	0.5988
4	2026-02-01	12.00	12.1567	0.5587
5	2026-03-01	12.50	12.5453	0.5851
6	2026-04-01	13.00	12.9694	0.5753
7	2026-05-01	13.25	13.2962	0.5171
8	2026-06-01	14.00	13.8594	0.3735
9	2026-07-01	14.00	13.8503	0.3650

```


fig, ax = plt.subplots(figsize=(11, 4.5))

ax.plot(df_selic['mes'], df_selic['Mediana'],
        marker='o', color='#1A6FB8', linewidth=1.8, label='Mediana')
ax.fill_between(df_selic['mes'],
                df_selic['Mediana'] - df_selic['DesvioPadrao'],
                df_selic['Mediana'] + df_selic['DesvioPadrao'],
                color='#1A6FB8', alpha=0.13, label='+/- 1 desvio-padrão')
ax.plot(df_selic['mes'], df_selic['Media'],
        linestyle='--', color='#555', linewidth=1.2, label='Média')

for _, row in df_selic.iterrows():
    ax.annotate(f"{row['Mediana']:.2f}",
                xy=(row['mes'], row['Mediana']),
                xytext=(0, 7), textcoords='offset points',
                ha='center', fontsize=8, color='#1A6FB8')

ano_ref = df_selic['DataReferencia'].iloc[0]
ax.set_title(f'Expectativa de Selic para {ano_ref} — mediana Focus (10 meses)', fontsize=11)
ax.set_xlabel('Mês da divulgação')
ax.set_ylabel('Taxa Selic esperada (%)')
ax.yaxis.set_major_formatter(mticker.FormatStrFormatter('%.2f%'))
ax.legend()
ax.grid(axis='y', alpha=0.3)
fig.tight_layout()
plt.savefig('ex1_selic_focus.png', dpi=120, bbox_inches='tight')
plt.show()

```



Por que a API é melhor do que raspar o boletim Focus?

O boletim Focus sai como PDF e a página HTML muda de estrutura com frequência — qualquer ajuste no layout quebra o scraper. Pela API Olinda os dados chegam em JSON estruturado direto da fonte, sem depender de como a página está montada. Outro ponto: fazer requisições repetidas a uma página web gera carga no servidor sem necessidade, enquanto a API existe exatamente para esse tipo de acesso.

Exercício 2 — Câmbio PTAX vs. Expectativa do Focus (Degrau 1)

Buscar o câmbio **PTAX (venda)** e as **expectativas Focus para o Câmbio** no ano de **2025**, visualizar cada distribuição e comparar as duas séries.

```
PTAX 2025: 253 cotações diárias
Período : 02/01/2025 a 31/12/2025
Min/Max : R$ 5.2729 / R$ 6.2086
```

	dataHoraCotacao	cotacaoVenda
0	2025-01-02 13:09:42.489	6.2086
1	2025-01-03 13:07:30.503	6.1563
2	2025-01-06 13:06:28.533	6.1119
3	2025-01-07 13:03:28.766	6.0741
4	2025-01-08 13:08:59.784	6.1321

```
df_cambio = buscar_focus('Câmbio', meses=24, ano=2025)
print(f'Focus Câmbio 2025: {len(df_cambio)} meses')
print(f'Mediana min/max : {df_cambio["Mediana"].min():.2f} / '
      f'{df_cambio["Mediana"].max():.2f}')
df_cambio[['mes', 'Mediana', 'Media', 'DesvioPadrao']].head()
```

```
Focus Câmbio 2025: 24 meses
Mediana min/max : 5.00 / 6.00
```

	mes	Mediana	Media	DesvioPadrao
0	2024-01-01	5.00	4.9799	0.1840
1	2024-02-01	5.00	4.9647	0.1831
2	2024-03-01	5.00	4.9833	0.1620
3	2024-04-01	5.05	5.0603	0.1420
4	2024-05-01	5.05	5.0665	0.1787

```

fig, axes = plt.subplots(1, 2, figsize=(13, 5))


ax1 = axes[0]
ax1.hist(df_ptax['cotacaoVenda'], bins=25, color='#B80D48',
         edgecolor='white', linewidth=0.6, alpha=0.85)
ax1.axvline(df_ptax['cotacaoVenda'].mean(), color='#333', linestyle='--',
            linewidth=1.4, label=f'Média: R$ {df_ptax["cotacaoVenda"].mean():.2f}')
ax1.axvline(df_ptax['cotacaoVenda'].median(), color='#666', linestyle=':',
            linewidth=1.4, label=f'Mediana: R$ {df_ptax["cotacaoVenda"].median():.2f}')
ax1.set_title('PTAX Venda 2025 – distribuição (dias úteis)', fontsize=10)
ax1.set_xlabel('R$ / US$'); ax1.set_ylabel('Frequência'); ax1.legend(fontsize=9)
ax1.grid(axis='y', alpha=0.3)

ax2 = axes[1]
ax2.hist(df_cambio['Mediana'], bins=12, color='#1A6FB8',
         edgecolor='white', linewidth=0.6, alpha=0.85)
ax2.axvline(df_cambio['Mediana'].mean(), color='#333', linestyle='--',
            linewidth=1.4, label=f'Média: R$ {df_cambio["Mediana"].mean():.2f}')
ax2.axvline(df_cambio['Mediana'].median(), color='#666', linestyle=':',
            linewidth=1.4, label=f'Mediana: R$ {df_cambio["Mediana"].median():.2f}')
ax2.set_title('Focus Câmbio 2025 – distribuição (mediana mensal)', fontsize=10)
ax2.set_xlabel('R$ / US$'); ax2.set_ylabel('Frequência'); ax2.legend(fontsize=9)
ax2.grid(axis='y', alpha=0.3)

fig.suptitle('Câmbio 2025: PTAX diário × Expectativa Focus', fontsize=11, y=1.01)
fig.tight_layout()
plt.savefig('ex2_cambio_comparativo.png', dpi=120, bbox_inches='tight')
plt.show()

```


Câmbio 2025: PTAX diário × Expectativa Focus



```
fig, ax = plt.subplots(figsize=(13, 4.5))

ax.plot(df_ptax['dataHoraCotacao'], df_ptax['cotacaoVenda'],
        color='#B80D48', linewidth=1.0, alpha=0.8, label='PTAX venda (diário)')
ax.plot(df_cambio['mes'], df_cambio['Mediana'],
        color='#1A6FB8', marker='o', linewidth=1.8, label='Focus – mediana mensal')
ax.fill_between(df_cambio['mes'],
                df_cambio['Mediana'] - df_cambio['DesvioPadrao'],
                df_cambio['Mediana'] + df_cambio['DesvioPadrao'],
                color='#1A6FB8', alpha=0.12, label='+/- 1 desvio-padrão')

ax.set_title('Câmbio 2025 – PTAX observado vs. Expectativa do Focus', fontsize=11)
ax.set_xlabel('Data'); ax.set_ylabel('R$ / US$')
ax.legend(fontsize=9); ax.grid(axis='y', alpha=0.3)
fig.tight_layout()
plt.savefig('ex2_cambio_serie.png', dpi=120, bbox_inches='tight')
plt.show()
```



Análise comparativa

A PTAX é a cotação diária realizada; a mediana Focus é a expectativa mensal do mercado para o câmbio no fim do ano. Em 2025 o dólar subiu de forma consistente e as projeções do Focus foram revisadas para cima junto — o gráfico de série temporal deixa essa relação visível.

Exercício 3 — Qual degrau? (Julgamento)

Para cada cenário, identificar o degrau correto da escada.

a) Preço de fechamento diário de uma ação — corretora tem endpoint REST documentado.

Degrau 1 (API). Tem endpoint documentado e mantido pela fonte — não precisa ir além.

b) Texto de uma norma que aparece só depois que o JavaScript do visualizador carrega.

Degrau 4 (Selenium). O HTML chega vazio; o conteúdo só existe depois que o JS roda no navegador.

c) Tabela de indicadores que só aparece após preencher um formulário e clicar em enviar.

Degrau 4 (Selenium com interação). Precisa preencher campo e clicar; só o Selenium faz isso.

d) Série histórica de IPCA que o IBGE disponibiliza como CSV para download.

Degrau 2 (dados abertos). O IBGE já entrega o arquivo; só baixar o CSV.

e) Notícias listadas no HTML de um portal, sem API, já presentes na resposta do servidor.

Degrau 3 (scraping estático). O conteúdo está no HTML; requests + BeautifulSoup resolvem.

Exercício 4 — Antes de raspar, leia os termos (Ética)

Investigação prévia ao scraping de `economia.uol.com.br`.

```

Fonte: HTTP 403 – usando cache

# economia.uol.com.br/robots.txt – obtido manualmente em 06/07/2026
User-agent: *
Disallow: /dev/
Disallow: /busca?q=
Disallow: /*.jhtm
Disallow: /next=

User-agent: DataForSeoBot
Disallow: /

User-agent: Diffbot
Disallow: /

User-agent: FacebookBot
Disallow: /

User-agent: Twitterbot
Disallow: /

Sitemap: https://economia.uol.com.br/sitemap.xml

```

Análise

Existe API ou dados abertos que tornam o scraping desnecessário?

Para câmbio e indicadores, sim: a API Olinda do BC já entrega o que o UOL exhibe. Para notícias editoriais não há API pública; checar o RSS seria o próximo passo.

O que dizem os Termos de Uso sobre acesso automatizado?

A política do UOL proíbe usos que gerem carga excessiva nos servidores e não autoriza expressamente acesso automatizado — na prática, scraping não está liberado.

O robots.txt permite as rotas pretendidas?

Para `User-agent:` só bloqueiam `/dev/`, `/busca?q=`, `/ .jhtm` e `/next=`. As rotas de notícias não aparecem no `Disallow`. Mesmo assim o UOL bloqueia completamente bots como Diffbot e DataForSeoBot, o que indica que o site não quer ser coletado.

robots.txt permite, mas Termos de Uso proíbem — o que prevalece?

Os Termos de Uso. O `robots.txt` é uma orientação técnica para indexadores, não tem força contratual. Os Termos criam uma obrigação entre o usuário e o site; violar isso é responsabilidade do coletor.

Exercício 5 — Abordagem de monitoramento (Degrau 4)

Para cada necessidade, indicar a abordagem mais adequada: **snapshot periódico**, **detecção de mudança** ou **sessão ao vivo**.

a) Reconstruir a série temporal completa do dólar minuto a minuto durante o pregão.

Snapshot periódico. A ideia é gravar cada leitura com o horário, mesmo que o valor não tenha mudado — o histórico completo é o resultado esperado.

b) Observar o número piscando em tempo real numa página que se atualiza sozinha.

Sessão ao vivo. O navegador fica aberto e relê o elemento continuamente; não precisa salvar tudo, só acompanhar o valor enquanto muda.

c) Disparar um alerta quando a cotação cruzar R\$ 5,50.

Detecção de mudança. Verifica periodicamente e só age quando o valor cruza o limiar; gasta menos armazenamento que o snapshot e é mais direto que manter sessão ao vivo.

Necessidade	Abordagem
Série temporal completa	Snapshot periódico
Acompanhar em tempo real	Sessão ao vivo
Alertar ao cruzar limiar	Detecção de mudança