



Universidade Federal de Ouro Preto

Instituto de Ciências Exatas e Aplicadas

CDD104 - Recuperação da Informação na Web e Redes Sociais

Professora: Helen De Cassia Sousa Da Costa Lima

Atividade Aula - 5




Aluno: Leonardo Isaac Silva Flores

Exercício 1

```
1 df_selic = buscar_foco('Selic', meses=10)
2
3 print('Indicador :', df_selic['Indicador'].iloc[0])
4 print('Ano-ref   :', df_selic['DataReferencia'].iloc[0])
5 print('Registros :', len(df_selic), 'meses')
6 print('Período   :', df_selic['mes'].min().strftime('%b/%Y'),
7       'a', df_selic['mes'].max().strftime('%b/%Y'))
8 print()
9 df_selic[['mes', 'Mediana', 'Media', 'DesvioPadrao']]
```

Indicador : Selic
Ano-ref : 2026
Registros : 10 meses
Período : Oct/2025 a Jul/2026

	mes	Mediana	Media	DesvioPadrao
0	2025-10-01	12.25	12.1750	0.6779
1	2025-11-01	12.00	12.1405	0.5770
2	2025-12-01	12.25	12.2225	0.6313
3	2026-01-01	12.25	12.2617	0.5988
4	2026-02-01	12.00	12.1567	0.5587
5	2026-03-01	12.50	12.5453	0.5851
6	2026-04-01	13.00	12.9694	0.5753
7	2026-05-01	13.25	13.2962	0.5171
8	2026-06-01	14.00	13.8594	0.3735
9	2026-07-01	14.00	13.8503	0.3650



Por que a API é melhor do que raspar o boletim Focus?

O boletim Focus sai como PDF e a página HTML muda de estrutura com frequência — qualquer ajuste no layout quebra o scraper. Pela API Olinda os dados chegam em JSON estruturado direto da fonte, sem depender de como a página está montada.

Outro ponto: fazer requisições repetidas a uma página web gera carga no servidor sem necessidade, enquanto a API existe exatamente para esse tipo de acesso.

Exercício 2

```
def buscar_ptax(ano=2025):
    ini = datetime(ano, 1, 1)
    fim = min(datetime(ano, 12, 31), datetime.now())
    base = ('https://olinda.bcb.gov.br/olinda/servico/PTAX/versao/v1/odata/'
           'CotacaoDolarPeriodo(dataInicial=@di,dataFinalCotacao=@df)')
    params = {
        '@di': f'"{ini.strftime('%m-%d-%Y')}"',
        '@df': f'"{fim.strftime('%m-%d-%Y')}"',
        '$format': 'json',
        '$select': 'cotacaoCompra,cotacaoVenda,dataHoraCotacao',
    }
    resp = requests.get(base, params=params, timeout=30)
    resp.raise_for_status()
    df = pd.DataFrame(resp.json().get('value', []))
    df['dataHoraCotacao'] = pd.to_datetime(df['dataHoraCotacao'])
    return df.sort_values('dataHoraCotacao').reset_index(drop=True)

df_ptax = buscar_ptax(2025)
print(f'PTAX 2025: {len(df_ptax)} cotações diárias')
print(f'Período : {df_ptax["dataHoraCotacao"].min():%d/%m/%Y} '
      f'a {df_ptax["dataHoraCotacao"].max():%d/%m/%Y}')
print(f'Min/Max : R$ {df_ptax["cotacaoVenda"].min():.4f} / '
      f'R$ {df_ptax["cotacaoVenda"].max():.4f}')
df_ptax[['dataHoraCotacao', 'cotacaoVenda']].head()
```


PTAX 2025: 253 cotações diárias
Período : 02/01/2025 a 31/12/2025
Min/Max : R\$ 5.2729 / R\$ 6.2086

	dataHoraCotacao	cotacaoVenda
0	2025-01-02 13:09:42.489	6.2086
1	2025-01-03 13:07:30.503	6.1563
2	2025-01-06 13:06:28.533	6.1119
3	2025-01-07 13:03:28.766	6.0741
4	2025-01-08 13:08:59.784	6.1321

```
1 df_cambio = buscar_focus('Câmbio', meses=24, ano=2025)
2 print(f'Focus Câmbio 2025: {len(df_cambio)} meses')
3 print(f'Mediana min/max : {df_cambio["Mediana"].min():.2f} / '
4       f'{df_cambio["Mediana"].max():.2f}')
5 df_cambio[['mes', 'Mediana', 'Media', 'DesvioPadrao']].head()
```

Focus Câmbio 2025: 24 meses
Mediana min/max : 5.00 / 6.00

	mes	Mediana	Media	DesvioPadrao
0	2024-01-01	5.00	4.9799	0.1840
1	2024-02-01	5.00	4.9647	0.1831
2	2024-03-01	5.00	4.9833	0.1620
3	2024-04-01	5.05	5.0603	0.1420
4	2024-05-01	5.05	5.0665	0.1787



Análise comparativa

A PTAX é a cotação diária realizada; a mediana Focus é a expectativa mensal do mercado para o câmbio no fim do ano. Em 2025 o dólar subiu de forma consistente e as projeções do Focus foram revisadas para cima junto — o gráfico de série temporal deixa essa relação visível.

Exercício 3

a) Preço de fechamento diário de uma ação — corretora tem endpoint REST documentado.

Degrau 1 (API). Tem endpoint documentado e mantido pela fonte — não precisa ir além.

b) Texto de uma norma que aparece só depois que o JavaScript do visualizador carrega.

Degrau 4 (Selenium). O HTML chega vazio; o conteúdo só existe depois que o JS roda no navegador.

c) Tabela de indicadores que só aparece após preencher um formulário e clicar em enviar.

Degrau 4 (Selenium com interação). Precisa preencher campo e clicar; só o Selenium faz isso.

d) Série histórica de IPCA que o IBGE disponibiliza como CSV para download.

Degrau 2 (dados abertos). O IBGE já entrega o arquivo; só baixar o CSV.

e) Notícias listadas no HTML de um portal, sem API, já presentes na resposta do servidor.

Degrau 3 (scraping estático). O conteúdo está no HTML; requests + BeautifulSoup resolvem.

Exercício 4

Análise

- Para câmbio e indicadores financeiros, sim. O UOL exibe dados que já estão disponíveis pela API Olinda do Banco Central — não faz sentido raspar o portal quando a fonte original entrega os mesmos números em JSON. O RSS seria o passo seguinte antes de partir para o Selenium.

- O UOL proíbe usos que gerem carga excessiva nos servidores e não autoriza acesso automatizado. Scraping não está liberado.

- Para User-agent: só /dev/, /busca?q=, /.jhtm e /next= estão bloqueados; rotas de notícias não aparecem. Mas o UOL bloqueia por completo Diffbot, DataForSeoBot e outros coletores — o site claramente não quer ser raspado.

- Os Termos de Uso. O robots.txt orienta indexadores mas não tem força contratual. Os Termos são um acordo com o usuário; desrespeitar é problema do coletor.

Exercício 5

a) Snapshot periódico. A ideia é gravar cada leitura com o horário, mesmo que o valor não tenha mudado — o histórico completo é o resultado esperado.

b) Sessão ao vivo. O navegador fica aberto e relê o elemento continuamente; não precisa salvar tudo, só acompanhar o valor enquanto muda.

c) Detecção de mudança. Verifica periodicamente e só age quando o valor cruza o limiar; gasta menos armazenamento que o snapshot e é mais direto que manter sessão ao vivo.

Necessidade	Abordagem
Série temporal completa	Snapshot periódico
Acompanhar em tempo real	Sessão ao vivo
Alertar ao cruzar limiar	Detecção de mudança

Referências:

<https://olinda.bcb.gov.br>

<https://dadosabertos.bcb.gov.br>

<https://economia.uol.com.br>

IDE AI: <https://kiro.dev/> prompt: “validar resolução dos exercícios, e indicar possíveis inconsistências conforme o enunciado”